

КУРСОВАЯ РАБОТА

Разработка автоматической диалоговой системы на основе языковой модели для анализа экономических новостей

Выполнил: Прудиев Алексей Сергеевич

Группа: ПМ23-4

Руководитель: доцент Романова Екатерина Владимировна


Москва, 2026

Актуальность

Экономические новости требуют быстрого поиска, фильтрации и интерпретации

Введение: актуальность

- Поток экономических новостей слишком велик для ручного анализа.
- Одно событие может по-разному влиять на рынок, компанию или сектор.
- Пользователю нужен ответ на естественном языке, но с проверяемыми источниками.
- Система объединяет retrieval, ML-оценку влияния и аналитический вывод.



Цель и задачи

Цель: разработать диалоговую систему для анализа экономических новостей

Введение: цель и задачи

Цель работы

Создать систему, которая принимает вопрос пользователя, находит релевантные экономические новости, оценивает их влияние и формирует ответ с источниками.

Задачи

- Подготовить датасет FNSPID и постановку ML-задачи.
- Сравнить три модели классификации влияния.
- Реализовать retrieval и RAG-ответ по источникам.
- Подключить внешнюю языковую модель для аналитического вывода.
- Собрать веб-интерфейс и микросервисную backend-архитектуру.

Данные и постановка задачи

FNSPID используется как корпус экономических новостей для обучения и анализа

Методы и результаты

50 000

строк в датасете

3

класса влияния

train / val / test

разделение выборки

Элемент	Описание
Объект анализа	экономическая новость
Вход модели	заголовок и полный текст новости
Целевая переменная	positive / neutral / negative
Проблема данных	шумная разметка и дисбаланс классов
Ключевая метрика	macro F1, так как важны все классы

Классификация используется не изолированно: ее результат входит в RAG-ответ и тематический прогноз.

ML-модели и метрики

Сравниваются простая, семантическая и легкая нейросетевая модель

Методы и результаты

Модель	Идея	Зачем нужна
tfidf-logreg	TF-IDF + Logistic Regression	быстрый и объяснимый baseline
embedding-logreg	embeddings + Logistic Regression	проверка семантических признаков
tiny-transformer-classifier	легкий transformer	нейросетевой вариант с малым потреблением ресурсов

- Accuracy показывает общую долю верных классификаций.
- Macro F1 показывает качество по каждому классу и важен при дисбалансе.
- Inference time нужен, чтобы оценить применимость модели в интерактивной системе.

Результаты моделей

Лучшее качество показала TF-IDF + Logistic Regression

Методы и результаты

Модель	Test accuracy	Test macro F1	Роль
tfidf-logreg	0.785	0.717	лучшая baseline-модель
embedding-logreg	0.594	0.515	семантический baseline
tiny-transformer-classifier	0.488	0.352	легкая нейросетевая модель


- TF-IDF + Logistic Regression стала наиболее устойчивой baseline-моделью.
- Качество ограничено шумом разметки, дисбалансом классов и сложностью экономического контекста.
- Выбранный baseline рационален для текущего RAG-сценария: он быстрый, объяснимый и воспроизводимый.

Лучший Test macro F1: 0.717 · тематических групп в прогнозе: 2 716

ML/RAG-пайплайн

Ответ формируется по найденным новостям, а не как абстрактная генерация

Методы и результаты



Шаг	Результат
Поиск	top-k релевантных новостей из Qdrant
Анализ	impact, confidence и объяснение для источников
RAG	ответ строится по найденному контексту
Прогноз	языковая модель формирует сценарный вывод по фактам


Микросервисная архитектура

Сервисы разделяют UI, поиск, анализ, диалог и работу с данными

Методы и результаты

Компактная микросервисная архитектура системы

Пользовательский интерфейс, API-слой, сервисы анализа, поиска, диалога и инфраструктурные хранилища



Архитектура оставляет ML-часть наблюдаемой: можно отдельно проверить данные, retrieval, классификацию и итоговую генерацию.

Страница чата

Пользователь получает ответ, источники и ход обработки запроса

LOCAL RAG PIPELINE

Аналитика экономических новостей

Диалоговая система, ML-оценка влияния и тематический прогноз по новостям.

Чат

RAG-ответ и источники

Данные

CSV, предпросмотр, индекс

ML-отчет

Метрики и ошибки моделей

Прогноз

Темы, риски, сценарии

Активный датасет

fnspid_sample.csv

Методы и результаты

Параметры анализа

Модель анализа

tfidf-logreg

Лимит источников

2

Источник

все источники

Вопрос

Что означает рост ВВП и снижение инфляции для рынка?

Спросить

По вопросу "Что означает рост ВВП и снижение инфляции для рынка?" найденные новости дают следующий ориентир. Факторы влияния: - Down 43%, Should Investors Buy the Dip in Meta Platforms?: влияние=негативное, уверенность=0.50. Модель классифицировала влияние новости как негативное. - Why Abbvie Is Down 5% in 2018 So Far: влияние=позитивное, уверенность=0.63. Модель классифицировала влияние новости как позитивное. Сценарий может измениться при появлении новых макроэкономических данных.

Ход обработки

1. чат запущен

2. поиск запущен

3. источники найдены

4. анализ запущен

5. анализ завершен

6. формирование ответа

7. ответ сформирован

8. готово

Источники

Down 43%, Should Investors Buy the Dip in Meta Platforms?

FNSPID

релевантность 1.00

негативное

Влияние: Модель классифицировала влияние новости как негативное.

Показать полный текст

Why Abbvie Is Down 5% in 2018 So Far

FNSPID

релевантность 1.00

позитивное

Влияние: Модель классифицировала влияние новости как позитивное.

Показать полный текст

- Вопрос задается на естественном языке.
- Ответ строится по найденным новостям.
- Источники показываются рядом с оценкой релевантности и ML-сигналом.
- Timeline делает обработку запроса прозрачной.

Прудиев Алексей Сергеевич · ПИМ23-4 · 9/15

Страница ML-отчета

Отчет показывает качество моделей и объясняет выбор baseline

LOCAL RAG PIPELINE

Аналитика экономических новостей

Диалоговая система, ML-оценка влияния и тематический прогноз по новостям.

Чат
RAG-ответ и источники

Данные
CSV, предпросмотр, индекс

ML-отчет
Метрики и ошибки моделей

Прогноз
Темы, риски, сценарии

Активный датасет
fnspid_sample.csv

ЭКСПЕРИМЕНТ

Качество моделей

ML-отчет

Сформировать ML-отчет

Лучшая модель: tfidf-logreg

Строк в датасете: 50000

negative: 3824 neutral: 23900 positive: 22276

Модель	Val accuracy	Val macro F1	Test accuracy	Test macro F1	Inference, сек
tfidf-logreg	0.784	0.724	0.785	0.717	0.000
embedding-logreg	0.607	0.538	0.594	0.515	0.041
tiny-transformer-classifier	0.485	0.380	0.488	0.352	0.001

Матрица ошибок

Факт \ прогноз	negative	neutral	positive
negative	178	121	7
neutral	166	1420	326
positive	15	226	1541

Качество по классам

negative: recall 0.582, F1 0.535 neutral: recall 0.743, F1 0.772 positive: recall 0.865, F1 0.843

Топ-признаки tfidf-logreg

negative
fell fall declined lower drop decline risk loss

neutral
decline of assets 2017 heavily about mixed loss per said on

positive
higher growth rose profit rise gain gains record

- Сравниваются три модели на одном test split.
- Отображаются accuracy, macro F1 и скорость инференса.
- Матрица ошибок помогает понять слабые классы.
- Топ-признаки показывают интерпретируемость TF-IDF baseline.

Страница прогноза

Система объединяет новости по темам и формирует сценарный вывод

LOCAL RAG PIPELINE

Аналитика экономических новостей

Диалоговая система, ML-оценка влияния и тематический прогноз по новостям.

Чат RAG-ответ и источники

Данные CSV, подробный просмотр, индексы

ML-отчет Метрики и ошибки моделей

Прогноз Темы, риски, сценарии

Активный датасет fnspid_sample.csv

ТЕМАТИЧЕСКИЕ ГРУППЫ

Сценарный прогноз

Прогноз по темам

Сформировать прогноз по темам

Сформировано: 2026-05-13T08:49:17.743409+00:00

Документов: 10000

Модель: tfidf-logreg

Celision Begins Patient Enrollment in Ovarian Cancer Study
Тема объединяет 5 новости: Celision Begins Patient Enrollment in Ovarian Cancer Study; AbbVie: FDA Grants Orphan Drug & Fast Track Designations For Elezanumab; Is American Airlines Recession-Proof?.

Прогноз темы

Общее влияние: нейтральное | Уверенность: 0.805 | Позитивных: 2 | Нейтральных: 2 | Негативных: 1

Прогноз

По совокупности новостей сигналы неоднозначны или сбалансированы; сценарий зависит от полноты новостного потока и качества impact-оценок.

Аргументы

- Оценка построена по большинству impact-меток внутри темы.
- Распределение сигналов: positive=2, neutral=2, negative=1.

Риски

- Баланс или отсутствие сигналов повышает неопределенность прогноза.

Новости

Celision Begins Patient Enrollment in Ovarian Cancer Study
FNSPID - нейтральное
Прогноз новости

AbbVie: FDA Grants Orphan Drug & Fast Track Designations For Elezanumab
FNSPID - нейтральное
Прогноз новости

Is American Airlines Recession-Proof?
FNSPID - негативное - 1.00
Прогноз новости

SPY ETF: A Shortcut to the Top 500 U.S. Stocks
FNSPID - позитивное
Прогноз новости

This Is Why Abbott Labs is a Great Stock to Buy Right Now
FNSPID - позитивное
Прогноз новости

What's in the Cards for ABM Industries (ABM) in Q2 Earnings?
Тема объединяет 5 новости: What's in the Cards for ABM Industries (ABM) in Q2 Earnings?; Next Coronavirus Market Crash: Where to Invest \$1,000; US Indexes Sitting Higher as Chinese Trade Data Eases Slowdown Concerns; Deal News Continues.

Прогноз темы

Общее влияние: позитивное | Уверенность: 0.711 | Позитивных: 3 | Нейтральных: 1 | Негативных: 1

Прогноз

По совокупности новостей преобладает положительный сигнал; сценарий зависит от полноты новостного потока и качества impact-оценок.

Аргументы

- Оценка построена по большинству impact-меток внутри темы.
- Распределение сигналов: positive=3, neutral=1, negative=1.

Риски

- Прогноз строится по 10 000 документам.
- Найдено 2 716 тематических групп.
- Для группы учитываются сигналы нескольких моделей.
- Подключаемая языковая модель формулирует прогноз по фактам из новостей.

Инженерная реализация

Backend поддерживает ML-сценарий, не подменяя исследовательскую часть

Методы и результаты

FastAPI + asyncio

асинхронные API и потоковые ответы через SSE

DDD и слои

domain, application, infrastructure, presentation, main

Protocol + Dishka

интерфейсы и сборка зависимостей без жесткой связности

Qdrant

векторный индекс для retrieval-поиска

Redis + Taskiq

фоновые задачи индексации и событийная обработка

MLflow

метрики, эксперименты и артефакты моделей

React UI

чат, данные, ML-отчет и прогноз

Главная идея: backend организует надежный путь данных от корпуса к ответу, а ML-компоненты остаются проверяемыми через отчет и метрики.

Ограничения и улучшения

Качество моделей можно повышать за счет данных, параметров и более сильных признаков

Методы и результаты

Текущие ограничения

- Разметка экономического влияния может быть шумной.
- Классы распределены неравномерно.
- Маленький transformer ограничен размером и режимом обучения.
- Retrieval-качество нужно оценивать отдельно от классификации.

Что улучшать

- Очистка и уточнение спорной разметки.
- Балансировка классов и подбор гиперпараметров.
- Более сильные embeddings и transformer-модель.
- Добавление признаков: сектор, компания, дата и источник.

Заключение

Реализована диалоговая ML-система для анализа экономических новостей

Заключение

Получено

- Подготовлен датасет FNSPID на 50 000 новостей.
- Сравнены три модели классификации влияния.
- Реализованы retrieval, RAG-ответ, ML-отчет и прогноз.
- Собрана микросервисная система с React UI.

Вывод

- Цель работы достигнута.
- Лучший baseline: TF-IDF + Logistic Regression.
- Система показывает полный путь: данные, модели, источники, ответ и прогноз.
- Проект соответствует теме курсовой работы.

Итог: проект объединяет диалоговый интерфейс, ML-анализ экономических новостей и подключаемую языковую модель.

Источники

Датасет, статьи и документация используемых технологий

Список источников

- Dong Z. et al. FNSPID: A Comprehensive Financial News Dataset in Time Series. URL: <https://arxiv.org/abs/2402.06698>
- FNSPID: A Comprehensive Financial News Dataset in Time Series : dataset. URL: <https://huggingface.co/datasets/beachside1234/FNSPID>
- Pedregosa F. et al. Scikit-learn: Machine Learning in Python. URL: <https://arxiv.org/abs/1201.0490>
- Scikit-learn documentation. URL: <https://scikit-learn.org/stable/>
- Paszke A. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. URL: <https://arxiv.org/abs/1912.01703>
- Wolf T. et al. HuggingFace's Transformers: State-of-the-art Natural Language Processing. URL: <https://arxiv.org/abs/1910.03771>
- Lewis P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. URL: <https://arxiv.org/abs/2005.11401>
- Qdrant documentation. URL: <https://qdrant.tech/documentation/>
- FastAPI documentation. URL: <https://fastapi.tiangolo.com/>
- MLflow documentation. URL: <https://mlflow.org/docs/latest/>