

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ
БЮДЖЕТНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«ФИНАНСОВЫЙ УНИВЕРСИТЕТ ПРИ ПРАВИТЕЛЬСТВЕ
РОССИЙСКОЙ ФЕДЕРАЦИИ»
(ФИНАНСОВЫЙ УНИВЕРСИТЕТ)**

**Кафедра искусственного интеллекта
Факультета информационных технологий и анализа больших данных**

Дисциплина: «Машинное обучение в семантическом и сетевом анализе»

Направление подготовки: «Прикладная математика и информатика»

Профиль: «Прикладное машинное обучение»

Факультет информационных технологий и анализа больших данных

Форма обучения очная

Учебный 2025/2026 год, 6 семестр

**Курсовая работа на тему:
«Разработка автоматической диалоговой системы на основе языковой модели
для анализа экономических новостей»**

Выполнил(а):

студент группы ПМ23-4

Прудиев Алексей Сергеевич

Научный руководитель:

доцент Романова Екатерина Владимировна

Москва 2026

Содержание

Введение	3
1. Теоретические основы анализа экономических новостей	4
2. Данные и постановка ML-задачи	6
3. Методы и модели	9
4. Архитектура программной системы	12
5. Реализация и пользовательский сценарий	15
6. Эксперимент и результаты	20
7. Направления улучшения	24
Заключение	26
Список использованных источников	28
Приложения	29

Введение

Экономические новости являются одним из основных источников оперативной информации о состоянии рынков, деловой активности, инфляционных ожиданий, занятости, торговых потоков и решений регуляторов. Для отдельного пользователя, аналитика или учебного исследователя поток таких сообщений становится слишком большим для ручного просмотра. При этом ценность имеет не только факт обнаружения новости, но и ее интерпретация: относится ли сообщение к положительному, отрицательному или нейтральному влиянию, какие источники подтверждают вывод и как кратко объяснить возможное значение события.

Актуальность работы определяется ростом объема текстовых экономических данных и необходимостью объединять поиск, машинное обучение и языковую модель в одном прикладном сценарии. Простая выдача списка документов не решает задачу анализа, поскольку пользователь ожидает связный ответ на естественном языке. Обычная генерация без источников также недостаточна, так как результат должен опираться на найденные материалы. Поэтому в работе рассматривается автоматическая диалоговая аналитическая система, которая сначала извлекает релевантный контекст из корпуса новостей, затем применяет классификаторы влияния и только после этого формирует ответ.

В качестве данных используется набор FNSPID объемом 50 000 экономических новостей. В рамках проекта решается задача классификации влияния новости по трем классам: positive, neutral и negative. Такая постановка связана с прикладным вопросом пользователя: не просто найти текст, а понять направленность события и использовать этот результат при формировании аналитического ответа. Дополнительно система поддерживает тематический прогноз по группам новостей и формирует ML-отчет с метриками моделей.

Объектом исследования являются экономические новости как источник текстовых данных для семантического анализа. Предметом исследования являются методы автоматической обработки этих новостей: текстовое представление, классификация влияния, поиск релевантных документов, retrieval-augmented generation и интеграция внешнего LLM API в пользовательский сценарий.

Цель курсовой работы состоит в разработке автоматической диалоговой системы для анализа экономических новостей, которая принимает вопрос пользователя, находит

релевантные документы, оценивает влияние новостей, формирует ответ на основе источников и отображает результаты в веб-интерфейсе.

Для достижения цели поставлены задачи: изучить теоретические основы NLP и анализа экономических новостей; подготовить датасет и формализовать ML-задачу; реализовать и сравнить несколько моделей классификации; спроектировать компактную backend-архитектуру; реализовать сценарий поиска, анализа и ответа; провести эксперимент, интерпретировать метрики и определить направления улучшения качества.

Практическая значимость работы состоит в том, что полученная система показывает полный путь от набора данных до пользовательского аналитического продукта. Она демонстрирует, как учебная ML-задача классификации может быть встроена в реальный диалоговый интерфейс, где важны не только метрики модели, но и воспроизводимость обработки, объяснимость результата, наличие источников и удобство просмотра отчета.

1. Теоретические основы анализа экономических новостей

Анализ экономических новостей относится к задачам обработки естественного языка, в которых текстовая информация преобразуется в признаки и используется для принятия аналитического решения. В отличие от числовых временных рядов, новостные данные содержат неструктурированные формулировки, контекст, неоднозначность и различный уровень детализации. Поэтому первым этапом становится приведение текста к форме, пригодной для поиска и классификации.

Классический подход к представлению текста строится на статистических признаках, например TF-IDF. Метод отражает важность слова или n-граммы в конкретном документе с учетом частоты в корпусе. Для экономических новостей такой подход полезен тем, что отдельные термины часто напрямую связаны с характером события: инфляция, рост, сокращение, ставка, безработица, экспорт, прибыль, дефицит. Модель на TF-IDF-признаках остается объяснимой и хорошо подходит как baseline.

Семантические embedding-представления решают другую задачу: они переводят текст в плотный вектор, где близость отражает не только буквальное совпадение слов, но и смысловую близость сообщений. Это особенно важно для retrieval-сценария, где пользователь может задать вопрос словами, отличающимися от текста новости. Например, запрос о снижении ценового давления должен находить новости об инфляции даже без полного совпадения формулировок.

Классификация влияния новостей представляет собой задачу supervised learning. Каждому тексту сопоставляется целевой класс: positive, neutral или negative. Positive означает потенциально благоприятное влияние на экономическую ситуацию или ожидания; negative указывает на риск или ухудшение; neutral фиксирует отсутствие явной направленности либо сбалансированное сообщение. В практическом применении такая классификация помогает не только упорядочить источники, но и объяснить итоговую позицию системы.

Retrieval-augmented generation объединяет поиск и генерацию ответа. Сначала система извлекает релевантные документы, затем передает их как контекст генератору ответа. В результате языковая модель не отвечает в отрыве от данных, а опирается на найденные новости. В проекте этот принцип применяется к экономическому домену: пользователь получает краткий аналитический ответ, а рядом видит источники, их релевантность и оценку влияния.

Языковые модели в аналитических системах выполняют роль компонента обобщения, а не единственного источника истины. Внешний LLM API используется после поиска и ML-анализа, поэтому его ответ ограничен переданным контекстом. Такой дизайн снижает риск нерелевантной генерации и соответствует требованию объяснимости: пользователь может проверить, какие новости были использованы при формировании вывода.

Для оценки качества классификаторов применяются ассигасу и макро F1. Ассигасу показывает долю верно классифицированных примеров, но при дисбалансе классов может переоценивать модель, хорошо распознающую только самый частый класс. Macro F1 усредняет качество по классам без учета их частоты, поэтому лучше показывает, насколько модель справляется с minor-классами и сохраняет полезность для анализа неоднородного новостного потока.

Экономические новости отличаются от обычных новостных текстов тем, что их значение часто зависит от контекста показателя. Рост одного показателя может быть положительным, а рост другого - отрицательным. Например, рост прибыли компании обычно воспринимается позитивно, а рост инфляции или безработицы может указывать на ухудшение макроэкономической ситуации.

Еще одна особенность домена состоит в наличии временного фактора. Новость может быть важна не только сама по себе, но и как часть последовательности сообщений. Повторяющиеся новости о снижении спроса, сокращении заказов или повышении ставки

формируют более сильный сигнал, чем единичная публикация. Поэтому тематический прогноз по группам новостей является естественным расширением задачи классификации.

В экономических текстах часто встречаются числовые показатели, названия компаний, индексы, регуляторы и отраслевые термины. Часть этих признаков важна для человека, но не всегда корректно используется простой моделью. Поэтому дальнейшее развитие системы может включать извлечение структурных признаков: сектора, тикера, даты, страны, показателя и направления изменения.

Для языковой модели экономический домен также создает ограничения. Модель может хорошо формулировать связный текст, но без найденных источников она не гарантирует актуальность и проверяемость вывода. Поэтому в проекте языковая модель используется после retrieval и ML-анализа. Она не заменяет корпус новостей, а преобразует найденный контекст в понятный ответ.

Такое понимание предметной области определяет структуру системы. Данные нужны не только для обучения, поиск нужен не только для интерфейса, классификация нужна не только для таблицы метрик, а языковая модель нужна не только для красивого текста. Все компоненты вместе решают одну прикладную задачу: дать пользователю краткий, проверяемый и объяснимый анализ экономических новостей.

Понятие	Значение для работы
NLP	Преобразует неструктурированный текст новостей в признаки для поиска и классификации.
Классификация влияния	Определяет направленность новости: positive, neutral или negative.
Retrieval	Находит релевантные источники по вопросу пользователя.
RAG	Формирует ответ на основе найденного контекста, а не только параметров языковой модели.
Внешний LLM API	Обобщает найденные документы и возвращает связный аналитический ответ.

2. Данные и постановка ML-задачи

Исходной базой исследования является датасет FNSPID, содержащий 50 000 экономических новостей. Для курсовой работы этот объем достаточен, чтобы обучить несколько моделей, получить устойчивые метрики и проверить работу поиска на реальном корпусе, а не на искусственном наборе демонстрационных фраз.

Каждая новость рассматривается как текстовый документ, в котором присутствуют заголовок, содержание или объединенное текстовое поле, а также метка влияния. В прикладной системе эти документы используются дважды: как обучающие примеры для классификаторов и как корпус для retrieval-поиска. Поэтому качество подготовки текста влияет одновременно на ML-метрики и на пользовательское качество ответа.

Целевая переменная принимает три значения: *negative*, *neutral*, *positive*. Наличие трех классов делает задачу более содержательной, чем бинарная оценка. Нейтральные новости важны, потому что в экономическом потоке значительная часть сообщений описывает факты без однозначной рыночной направленности. Если игнорировать этот класс, система будет искусственно усиливать позитивную или негативную интерпретацию.

Перед обучением выполняется базовая подготовка текста: удаление пустых значений, приведение записей к единой схеме, проверка целевой метки, формирование обучающего и тестового представления. Для моделей на TF-IDF важна стабильность токенизации и ограничение словаря, чтобы случайные редкие слова не перегружали признаковое пространство. Для *embedding*-подхода важна сохранность семантического содержания фразы.

Данные делятся на *train*, *validation* и *test*. Обучающая часть используется для подбора параметров модели, *validation* помогает контролировать качество в процессе настройки, *test* применяется только для итогового сравнения. Такое разделение необходимо, чтобы метрики отражали обобщающую способность модели, а не запоминание конкретных новостей.

Особое внимание уделяется дисбалансу классов. В новостных данных одни типы сообщений встречаются чаще других: нейтральные публикации могут доминировать над явно позитивными или негативными. В такой ситуации модель может показывать приемлемую ассигасу, но плохо распознавать редкие классы. Поэтому в отчете рядом с ассигасу обязательно анализируется *macro F1*.

С точки зрения пользовательского сценария датасет используется не изолированно, а как активный источник знаний. После индексации новости становятся доступными для поиска по вопросу пользователя. Это связывает исследовательскую часть с программной реализацией: корпус, на котором обучается классификатор, одновременно является базой фактов для RAG-ответа и тематического прогноза.

Для экономических новостей особенно важна воспроизводимость подготовки корпуса. Если одна и та же новость в разных экспериментах получает различное представление, сравнение моделей теряет смысл. Поэтому подготовка данных должна быть детерминированной: одинаковые правила очистки, одинаковое разбиение, одинаковая интерпретация целевой колонки и одинаковые ограничения на признаки.

Еще одна особенность датасета состоит в том, что экономическая направленность часто выражается не одним словом, а сочетанием показателя и контекста. Например, рост инфляции может восприниматься негативно, но рост выручки компании обычно положителен. Это означает, что модель должна учитывать локальные словосочетания, а не только отдельные токены. Поэтому для TF-IDF полезны n-граммы, а для transformer-подхода важен достаточно длинный контекст.

В прикладном RAG-сценарии качество данных проявляется и через источники, которые видит пользователь. Если корпус содержит дубликаты, пустые тексты или нерелевантные записи, retrieval может вернуть слабый контекст даже при хорошей модели классификации. Поэтому работа с данными рассматривается как отдельная часть проекта, а не как вспомогательная техническая операция.

Полный путь обработки в системе начинается с загрузки новостного корпуса. На этом этапе данные приводятся к единой схеме: идентификатор новости, заголовок, полный текст, источник, дата публикации и целевая метка влияния. Такая унификация нужна для того, чтобы один и тот же корпус можно было использовать и в исследовательском ML-пайплайне, и в пользовательском RAG-сценарии.

После подготовки новости индексируются для поиска. Индексация решает отдельную задачу: система должна находить документы не только по точному совпадению слов, но и по смысловой близости к вопросу пользователя. Поэтому retrieval-компонент является самостоятельной частью решения, а не вспомогательной функцией интерфейса.

Когда пользователь задает вопрос, API Gateway передает запрос в диалоговый сценарий. Сначала retrieval-service выбирает релевантные новости, затем analysis-service оценивает их влияние с помощью ML-модели, после чего dialog-service формирует контекст для ответа. Внешняя языковая модель получает уже подготовленный контекст, а не исходный вопрос без ограничений.

Такой порядок важен для надежности результата. Если языковая модель отвечает без источников, пользователь не может проверить, какие факты лежат в основе вывода. В

реализованной системе ответ связан с конкретными документами: они показываются в интерфейсе вместе с оценками релевантности и ML-сигналами.

Элемент постановки	Описание
Объект	Экономическая новость как текстовый документ.
Целевая переменная	Класс влияния: positive, neutral, negative.
Вход модели	Очищенный текст новости или embedding-представление.
Выход модели	Предсказанный класс, confidence score и объяснение для интерфейса.
Метрики	Accuracy и macro F1 на тестовом наборе.

3. Методы и модели

В работе сравниваются три подхода к классификации влияния экономических новостей. Такое сравнение выбрано намеренно: оно показывает разницу между классическим статистическим baseline, семантическими embedding-признаками и легкой нейросетевой моделью. Для курсовой работы важно не только получить лучший результат, но и объяснить, почему разные методы ведут себя по-разному на одном наборе данных.

Первая модель, TF-IDF + Logistic Regression, служит основным baseline. TF-IDF преобразует текст в разреженный вектор признаков, а логистическая регрессия обучает линейную границу между классами. Преимущество подхода состоит в скорости, воспроизводимости и интерпретируемости. Если модель показывает высокое качество, это означает, что в данных есть достаточно сильные лексические сигналы, связанные с классом влияния.

Вторая модель, embedding-logreg, использует sentence embeddings как признаки для логистической регрессии. Она должна лучше учитывать смысловую близость текстов, но результат зависит от того, насколько embedding-модель соответствует языку, домену и стилю новостей. На текущей разметке embedding-подход оказался слабее TF-IDF, что указывает на важность доменных слов и явных лексических маркеров в задаче влияния.

Третья модель, tiny-transformer-classifier, представляет легкий transformer-классификатор. Такой вариант включен для проверки нейросетевого подхода, однако маленький размер модели и ограниченный режим обучения сдерживают качество. Transformer-модели обычно требуют более аккуратной настройки, достаточного времени

обучения, баланса классов и стабильной разметки, иначе они могут проиграть простому baseline.

Все модели оцениваются на одном тестовом разбиении, что делает сравнение корректным. Для каждой модели фиксируются test accuracy и test macro F1. Accuracy удобна для общей оценки, а macro F1 показывает, насколько равномерно модель работает по всем классам. Это особенно важно для экономических новостей, где ошибки на редком негативном классе могут быть прикладно значимее, чем ошибки на частом нейтральном классе.

Выбор нескольких моделей также полезен для архитектуры системы. Пользовательский интерфейс и API не должны зависеть от конкретного классификатора. Если в будущем будет обучена более сильная модель, ее можно подключить в analysis-service без изменения сценария чата, отчета и прогноза. Такое разделение повышает устойчивость проекта как программной системы.

TF-IDF baseline также удобен для анализа ошибок. После обучения можно посмотреть, какие слова и словосочетания сильнее всего связаны с каждым классом. Это помогает понять, действительно ли модель выучила экономически осмысленные признаки или опирается на случайные артефакты корпуса. Для учебной работы такая объяснимость важна не меньше абсолютного значения метрики.

Embedding-подход полезен как проверка гипотезы о смысловой близости. Если две новости описывают одно и то же экономическое явление разными словами, embedding должен расположить их рядом в векторном пространстве. Даже если итоговая классификация оказалась слабее TF-IDF, этот подход остается значимым для retrieval и дальнейшего развития поиска.

Transformer-классификатор включен как исследовательский ориентир. Он показывает, что архитектура проекта допускает более сложные модели, но одновременно демонстрирует необходимость аккуратной экспериментальной дисциплины. Нейросетевая модель требует контроля переобучения, качества токенизации, длины входа, баланса классов и достаточного количества эпох.

Сравнение моделей не ограничивается выбором победителя. Оно формирует практическое решение для текущей версии системы: использовать лучший baseline в пользовательском сценарии, сохранить альтернативные подходы в отчете и зафиксировать, какие условия нужны для повышения качества в следующих итерациях.

Подбор гиперпараметров в работе рассматривается как способ проверить устойчивость выбранного baseline. Для TF-IDF-модели важны размер словаря, диапазон n-грамм, минимальная частота токена, максимальная доля документов для слишком частых слов и коэффициент регуляризации логистической регрессии.

Автоматический подбор параметров может выполняться по сетке с использованием validation split. В качестве критерия целесообразно использовать macro F1, потому что он лучше отражает качество на всех классах при дисбалансе данных. Это соответствует постановке задачи: система должна распознавать не только самый частый класс, но и менее представленные negative/neutral-сигналы.

Для embedding-logreg гиперпараметры связаны не только с классификатором, но и с представлением текста. В дальнейшем можно сравнивать разные embedding-модели, нормализацию векторов и параметры логистической регрессии. Для transformer-классификатора наиболее значимы learning rate, batch size, число эпох, max length и веса классов.

В текущей версии проекта основной упор сделан на воспроизводимое сравнение трех классов моделей. Поэтому сложный подбор параметров вынесен в направления развития, а в основной эксперимент включены варианты, которые можно запустить локально и объяснить на защите без чрезмерного усложнения кода.

Экспериментальный протокол в работе строится так, чтобы сравнение моделей было воспроизводимым. Все модели обучаются и оцениваются на одной и той же подготовленной выборке, используют одинаковый набор классов и возвращают результат в общем формате. Это исключает ситуацию, когда улучшение метрики связано не с моделью, а с изменением данных или правил оценки.

Для корректной интерпретации результатов важно разделять validation и test. Validation используется для контроля настройки и выбора рационального варианта, а test должен оставаться финальной проверкой. Если многократно подбирать параметры по test, итоговая метрика перестанет отражать реальное обобщение модели на новых новостях.

В ML-отчете рядом с метриками показывается матрица ошибок. Она нужна для ответа на вопрос, какие классы путаются чаще всего. Для экономических новостей такая информация особенно важна: нейтральное сообщение может содержать слова роста или падения, но не нести однозначного сигнала; негативная новость может быть написана формально и не содержать явных эмоциональных маркеров.

Еще один элемент протокола - контроль времени инференса. В исследовательской задаче можно обучить тяжелую модель, но в диалоговой системе пользователь ожидает ответ без долгого ожидания. Поэтому модель оценивается не только по качеству, но и по скорости применения. Быстрый baseline имеет практическое преимущество, если его качество достаточно для текущего сценария.

Сохранение результатов в MLflow делает эксперимент воспроизводимым. В дальнейшем можно сравнить новые версии признаков, параметры моделей и результаты на одном отчете. Для курсовой работы это важно, потому что демонстрирует не только разовый запуск, но и основу для дальнейшей исследовательской работы.

Модель	Сильная сторона	Ограничение
TF-IDF + Logistic Regression	Высокая скорость, объяснимость, сильный baseline.	Зависимость от лексических совпадений и словаря.
embedding-logreg	Учитывает смысловую близость текстов.	Может терять важные доменные маркеры текущей разметки.
tiny-transformer-classifier	Проверяет нейросетевой подход.	Ограничен размером модели и режимом обучения.

4. Архитектура программной системы

Программная система построена как набор связанных сервисов, каждый из которых отвечает за отдельный этап аналитического сценария. Архитектура описывается компактно, поскольку основной фокус работы находится на данных, моделях и результатах эксперимента. Тем не менее разделение backend-компонентов важно: оно показывает, как ML-логика встроена в приложение, а не остается отдельным исследовательским скриптом.

Frontend на React предоставляет пользователю страницы чата, ML-отчета и тематического прогноза. API Gateway принимает запросы от интерфейса и координирует обращение к сервисам анализа, поиска и диалога. News-service отвечает за корпус новостей и подготовку данных для индексации. News-worker выполняет фоновые задачи, чтобы тяжелая обработка не блокировала пользовательский запрос.

Retrieval-service отвечает за поиск релевантных документов в векторном хранилище Qdrant. Сервис возвращает новости, которые по смыслу ближе всего к вопросу пользователя. Analysis-service применяет ML-модель и определяет влияние найденных новостей. Dialog-service получает вопрос, контекст и результаты анализа, после чего

формирует итоговый ответ, используя внешний LLM API или резервный шаблонный режим.

Redis применяется для очередей и событий, Qdrant хранит векторный индекс новостей, MLflow фиксирует результаты экспериментов и артефакты моделей. Такой набор инфраструктурных компонентов достаточен для учебного проекта: он демонстрирует production-подход, но не перегружает курсовую работу деталями промышленной эксплуатации.

Ключевой архитектурный принцип состоит в том, что внешняя языковая модель не заменяет ML-часть. Она получает уже найденный и предварительно проанализированный контекст. Поэтому система остается объяснимой: можно отдельно проверить корпус данных, retrieval-результаты, классификацию влияния и итоговую генерацию.

Границы сервисов выбраны так, чтобы каждая часть могла развиваться независимо. Например, retrieval-service может менять способ построения embeddings и параметры поиска без изменения интерфейса чата. Analysis-service может подключить новый классификатор, сохранив прежний формат ответа. Dialog-service может изменить стратегию промпта или поставщика внешнего LLM API, не затрагивая подготовку датасета и ML-отчет.

Компактность backend-описания не означает упрощения ML-сценария. Напротив, архитектура нужна для того, чтобы экспериментальная часть была доступна пользователю через приложение: результаты моделей отображаются в отчете, найденные источники выводятся в чате, а прогноз строится по индексированному корпусу. Поэтому программная структура поддерживает исследовательскую логику курсовой работы.

Такой подход также упрощает диагностику ошибок. Если пользователь получает слабый ответ, можно последовательно проверить этапы: был ли корректно подготовлен корпус, нашел ли retrieval релевантные документы, правильно ли analysis-service оценил влияние, достаточно ли контекста получил dialog-service. Разделение компонентов делает качество системы наблюдаемым.

Слоистая структура сервисов помогает отделить бизнес-логику от инфраструктуры. Доменный слой описывает сущности и правила предметной области, application-слой реализует сценарии использования, infrastructure-слой отвечает за базы, внешние API и очереди, а presentation-слой принимает HTTP-запросы. Такое разделение делает код более поддерживаемым и упрощает замену отдельных компонентов.

Использование Protocol для интерфейсов позволяет описывать зависимости через ожидаемое поведение, а не через конкретные классы. Например, application-слой может требовать абстрактный репозиторий новостей или абстрактный клиент языковой модели. Конкретная реализация подключается снаружи, поэтому сценарий не зависит напрямую от Qdrant, Redis или внешнего API.


Dishka используется для сборки зависимостей. Это важно в микросервисной архитектуре, потому что каждый сервис имеет собственные адаптеры и собственную точку входа, но общие подходы к конфигурации и зависимостям остаются одинаковыми. Благодаря этому в проекте можно поддерживать современную архитектуру без дублирования большого количества технического кода.

Фоновые задачи вынесены отдельно, чтобы тяжелая индексация корпуса не блокировала пользовательский интерфейс. Пользовательский запрос должен обрабатываться быстро, а подготовка данных, переиндексация и расчет отчетов могут выполняться асинхронно. Redis и Taskiq закрывают этот сценарий без добавления более тяжелого брокера сообщений.

Микросервисность в проекте не используется ради количества сервисов. Каждый сервис связан с отдельной ролью в ML/RAG-процессе: новости, поиск, анализ, диалог, API Gateway и интерфейс. Поэтому архитектура помогает объяснить систему на защите: можно показать не только код, но и движение данных между компонентами.

Компактная микросервисная архитектура системы

Пользовательский интерфейс, API-слой, сервисы анализа, поиска, диалога и инфраструктурные хранилища



Архитектура оставляет backend компактным: каждый сервис закрывает одну прикладную роль ML/RAG-сценария.

Схема 1 - Компактная архитектура программной системы

ML/RAG-пайплайн анализа экономических новостей




Схема 2 - ML/RAG-пайплайн обработки вопроса

5. Реализация и пользовательский сценарий

Пользовательский сценарий начинается с естественного вопроса об экономической ситуации. Пользователь не обязан знать структуру датасета или формулировать запрос в виде ключевых слов. Система принимает текст вопроса, передает его в backend и запускает цепочку retrieval, ML-анализа и генерации ответа.

На этапе поиска retrieval-service извлекает несколько наиболее релевантных новостей. Для каждой найденной записи сохраняются заголовок или краткое описание, источник, score релевантности и текстовый фрагмент. Эти данные нужны не только для ответа, но и для интерфейса: пользователь должен видеть, на каких материалах основан вывод.

После поиска analysis-service применяет классификатор влияния. Результат включает класс positive, neutral или negative, численную уверенность и краткое объяснение. Эти признаки помогают dialog-service сформировать не абстрактный пересказ, а аналитический ответ с учетом направленности найденных новостей.

Dialog-service собирает промпт для внешнего LLM API на основе вопроса, найденных документов и оценок влияния. Важным ограничением является использование только переданного контекста: ответ должен объяснять найденные новости, а не подменять их внешними рассуждениями. Если внешний API недоступен, система может использовать резервный шаблонный ответ, сохраняя работоспособность базового сценария.

Страница чата показывает центральный результат проекта: вопрос, ответ, список источников и статусы обработки. Это делает ML/RAG-процесс видимым для пользователя. Вместо обычного чат-бота реализована аналитическая система, где ответ связан с корпусом новостей и сопровождается проверяемыми источниками.

Страница ML-отчета предназначена для контроля исследовательской части. В ней отображаются размер датасета, список обученных моделей, метрики качества и интерпретация результатов. Наличие такой страницы важно для защиты, потому что показывает, что система основана на сравнении моделей, а не только на интерфейсной демонстрации.

Страница прогноза показывает агрегированный анализ тем. В текущих фактах проекта отражено, что прогноз строится по 10 000 документам и 2 716 темам. Этот сценарий расширяет обычный поиск: пользователь видит не только ответ на отдельный вопрос, но и тематическое обобщение корпуса новостей.

В реализации важно, что пользовательский интерфейс не скрывает исследовательскую природу проекта. Чат демонстрирует конечный сценарий, ML-отчет показывает качество моделей, а прогноз показывает агрегированную работу с корпусом. Эти три страницы вместе образуют полный контур: данные, модель, поиск, ответ и интерпретация результата.

Сценарий работы с источниками также важен для доверия к системе. Пользователь может сопоставить итоговый ответ с найденными карточками новостей и увидеть, какие документы повлияли на вывод. Для экономической аналитики это принципиально: ответ без проверяемых источников сложнее использовать и сложнее защищать как результат машинного обучения.

ML-отчет выполняет роль внутреннего контроля качества. Если в дальнейшем изменится датасет, признаки или модель, отчет позволит быстро увидеть, улучшилось ли качество на test split или изменения только усложнили систему без прироста метрик. Поэтому отчет встроен в приложение как часть жизненного цикла модели.

Сценарный прогноз в проекте построен как агрегирование новостей по близким темам. Это делает систему полезнее обычного поиска: пользователь видит не только отдельные документы, но и группу сообщений, которые описывают похожий экономический сюжет. Такой подход помогает понять, является ли сигнал единичным событием или повторяется в нескольких публикациях.

Для каждой группы новостей система учитывает оценки трех моделей и распределение классов влияния. Если в группе преобладают negative-сигналы, интерфейс показывает соответствующее направление сценария; если положительные и отрицательные сигналы сбалансированы, вывод становится осторожнее. Это снижает риск слишком уверенной интерпретации по одной новости.

Подключаемая языковая модель используется для формулирования прогноза на естественном языке. При этом она получает полный текст выбранных новостей и рассчитанные ML-сигналы. Поэтому ее роль состоит в аналитическом обобщении фактов, а не в генерации произвольного ответа без опоры на корпус.

С точки зрения курсовой работы этот режим важен, потому что связывает ML-классификацию, retrieval и диалоговую генерацию в один пользовательский сценарий. Прогноз показывает, как результаты моделей могут быть применены не только для метки отдельной новости, но и для объяснения общей картины в группе экономических событий.

Качество retrieval-компонента влияет на итоговый ответ не меньше, чем качество классификатора. Если поиск возвращает нерелевантные новости, даже сильная языковая модель будет формировать вывод по слабому контексту. Поэтому в RAG-системе важно отдельно анализировать, какие документы попадают в top-k и насколько они действительно отвечают на вопрос пользователя.

В текущей версии retrieval используется как практический компонент поиска источников. Для дальнейшего развития можно ввести ручную разметку релевантности по набору типовых вопросов и считать precision@k. Такая оценка позволит понять, какие запросы работают хуже: общие макроэкономические вопросы, вопросы по компаниям, отраслевые темы или запросы с косвенными формулировками.

Важным элементом пользовательского доверия является отображение найденных источников. Если система показывает только итоговый текст, пользователь не видит, почему был сделан вывод. Если рядом есть новости, score релевантности и ML-сигнал, результат становится проверяемым. Это особенно важно для экономической аналитики, где вывод должен иметь фактическую опору.

RAG-подход в проекте не отменяет необходимость классификации. Retrieval находит документы, но не объясняет, какое влияние они несут. Классификатор добавляет структурированный сигнал, а языковая модель превращает найденные факты и сигналы в

связный ответ. Таким образом, три компонента выполняют разные роли и дополняют друг друга.

Пользовательский интерфейс в проекте выполняет не только демонстрационную функцию. Он связывает исследовательские результаты с понятным сценарием работы. Страница чата показывает прикладной результат, страница ML-отчета раскрывает качество моделей, а страница прогноза демонстрирует агрегированную аналитику по корпусу.

Такое разделение страниц помогает проверять систему на защите. Если требуется показать тему курсовой, достаточно открыть чат и задать вопрос по экономическим новостям. Если нужно обосновать ML-часть, открывается отчет с метриками, матрицей ошибок и признаками. Если нужно показать использование нескольких новостей по одной теме, используется страница прогноза.

В интерфейсе важно избегать чрезмерной имитации готового промышленного продукта. Курсовая работа должна показывать, как работает метод и какие ограничения он имеет. Поэтому в приложении сохраняются исследовательские элементы: метрики, распределение классов, источники, статусы обработки и возможность сравнить модели.

С точки зрения пользователя, наиболее ценным является связный путь от вопроса до проверяемого вывода. Пользователь вводит запрос, видит найденные источники, получает ответ, а при необходимости переходит к ML-отчету и проверяет качество модели. Такой сценарий делает систему понятной и защищаемой как учебный ML-проект.




Рисунок 1 - Страница чата




Рисунок 2 - Страница ML-отчета




Рисунок 3 - Страница прогноза

6. Эксперимент и результаты

Экспериментальная часть направлена на сравнение трех моделей классификации влияния новостей. Все модели решают одну и ту же задачу, используют общий набор классов и оцениваются по test accuracy и test macro F1. Такой дизайн эксперимента позволяет сопоставить методы без смещения факторов, связанных с разными данными или разными метриками.

Лучший результат показала модель tfidf-logreg с test accuracy 0.785 и test macro F1 0.717. Это означает, что классический TF-IDF baseline оказался наиболее устойчивым на текущем корпусе и разметке. Для экономических новостей такой результат объясним: многие признаки влияния выражены лексически и хорошо фиксируются частотными признаками.

Embedding-logreg уступила TF-IDF. Возможная причина состоит в том, что универсальные embedding-признаки сглаживают отдельные доменные маркеры, важные для тонкой классификации влияния. В задаче, где слова о росте, падении, ставке, инфляции или риске напрямую связаны с меткой, простая разреженная модель может сохранять больше полезной информации.

Tiny-transformer-classifier показала самый слабый результат среди трех моделей. Это не означает, что transformer-подход неприменим к задаче. Скорее, результат отражает ограничения маленькой модели, режима обучения и качества разметки. Для уверенного преимущества transformer-классификатора требуются более сильная модель, больше вычислительных ресурсов, настройка гиперпараметров и работа с дисбалансом классов.

Macro F1 рассматривается как ключевая дополнительная метрика, потому что новостные классы могут быть распределены неравномерно. Если модель правильно классифицирует большинство нейтральных сообщений, но пропускает негативные или позитивные новости, ассигасу будет выглядеть приемлемо, однако прикладная ценность снизится. Macro F1 штрафует такую ситуацию и поэтому лучше отражает качество по всем типам влияния.

Полученные метрики являются умеренными, но содержательно полезными. Они показывают, что задача не сводится к простому словарному правилу и требует дальнейшей работы с данными. При этом лучший baseline уже может использоваться как компонент RAG-системы: он дает первичную оценку влияния источников, которую затем учитывает внешний LLM API при формировании ответа.

Эксперимент также показал инженерную ценность ML-отчета. Пользователь или проверяющий может видеть не только итоговый ответ, но и сведения о том, какие модели были обучены и с каким качеством. Это повышает доверие к системе и делает проект ближе к полноценному аналитическому приложению.

Интерпретация результатов должна учитывать учебный характер набора моделей. Цель эксперимента не состояла в том, чтобы любой ценой получить максимальную метрику. Важнее было построить воспроизводимое сравнение разных классов подходов и показать, какой вариант рационально использовать в текущей версии приложения. По этому критерию TF-IDF + Logistic Regression является обоснованным выбором.

Для анализа качества важно смотреть не только на средний результат, но и на типичные ошибки. Нейтральные новости могут ошибочно относиться к позитивным или негативным, если содержат слова с яркой эмоциональной окраской, но описывают факт без явного рыночного эффекта. Обратная ситуация возникает, когда негативное событие описано формально и без сильных маркеров риска.

Результаты эксперимента прямо влияют на пользовательский сценарий. Если модель ошибается, внешний LLM API может получить искаженную оценку влияния источника. Поэтому классификатор должен рассматриваться как часть общей цепочки

качества: слабая метка ухудшает контекст, а слабый контекст снижает ценность итогового ответа.

В текущей версии системы метрики достаточны для демонстрации полного ML/RAG-процесса, но не должны трактоваться как финальный промышленный уровень качества. Для перехода к более строгому применению необходимо расширять оценку: смотреть confusion matrix, качество по каждому классу, устойчивость на новых источниках и поведение модели при изменении новостной тематики.

Проверка переобучения выполняется через сравнение качества на validation и test, а также через анализ матрицы ошибок. Если модель показывает высокое качество на обучающих данных, но резко теряет macro F1 на тесте, это означает, что она запомнила особенности train split и плохо обобщает новые новости.

В текущем проекте важна не только абсолютная метрика, но и стабильность выводов. TF-IDF + Logistic Regression является более устойчивым вариантом, потому что линейная модель на регуляризованных признаках меньше склонна к переобучению, чем маленький transformer при ограниченном режиме обучения.

Дополнительным индикатором является интерпретация признаков. Если среди top-признаков появляются осмысленные экономические маркеры, например growth, higher, fell, lower, это подтверждает, что модель использует содержательные сигналы. Если бы top-признаки состояли из случайных артефактов, доверие к модели было бы ниже.

Типичные ошибки классификации связаны с тем, что экономический текст часто описывает несколько эффектов одновременно. Например, рост выручки компании является позитивным сигналом, но если он сопровождается ростом затрат или снижением маржинальности, итоговая оценка может быть менее очевидной. Простая модель на словах может зафиксировать только часть такого контекста.

Часть ошибок возникает из-за различий между общим настроением текста и экономическим влиянием. Новость может быть написана нейтральным стилем, но описывать существенный негативный риск. Обратная ситуация также возможна: эмоционально окрашенный заголовок может не соответствовать реальному экономическому эффекту. Поэтому задача классификации влияния сложнее обычного sentiment analysis.

Ошибки embedding-модели могут объясняться тем, что универсальные смысловые векторы сглаживают важные доменные слова. Для общего поиска это полезно, но для классификации влияния иногда важны конкретные маркеры: fell, lower, profit, approval,

inflation. TF-IDF сохраняет такие признаки явно, поэтому на текущем корпусе показывает более сильный результат.

Ошибки transformer-классификатора в текущей версии связаны не с непригодностью transformer-подхода, а с ограничениями выбранного легкого режима. Маленькая модель требует аккуратной настройки, достаточного числа эпох, контроля learning rate и работы с классами. Без этого она может либо недообучиться, либо запомнить поверхностные признаки train split.

Практический вывод из анализа ошибок состоит в том, что улучшать нужно не только архитектуру модели. Значительную роль играют качество разметки, баланс классов, очистка дублей, длина входного текста и учет экономического контекста. Поэтому направления развития включают работу с данными наравне с подбором более сложных моделей.

При интерпретации эксперимента необходимо учитывать угрозы валидности. Первая угроза связана с происхождением меток: если метка влияния получена автоматически или косвенно, она может не полностью совпадать с экспертной оценкой экономиста. В этом случае модель обучается не идеальной истине, а приближенной разметке.

Вторая угроза связана с тематическим составом корпуса. Если в выборке много новостей о компаниях одного типа или о конкретных рыночных событиях, модель может переоценить признаки, характерные именно для этих тем. На новых источниках или в другом периоде распределение слов и событий может измениться.

Третья угроза связана с языком и стилем новостей. Экономические публикации могут быть короткими заголовками, длинными аналитическими текстами или пресс-релизами. Эти форматы по-разному выражают влияние. Поэтому в дальнейшем полезно анализировать качество отдельно для заголовков, полных текстов и разных источников.

Четвертая угроза связана с тем, что итоговая система объединяет несколько компонентов. Даже если классификатор работает приемлемо, слабый retrieval может ухудшить ответ. И наоборот, хороший поиск не компенсирует неверную оценку влияния. Поэтому в развитии проекта нужно оценивать не только отдельные модели, но и весь пользовательский сценарий.

Эти ограничения не отменяют результата работы, но задают корректные рамки интерпретации. В курсовой работе важно показать не только достигнутые метрики, но и

понимание того, почему они получились именно такими и какие шаги нужны для повышения качества.

Модель	Test accuracy	Test macro F1	Интерпретация
tfidf-logreg	0.785	0.717	лучшая baseline-модель
embedding-logreg	0.594	0.515	уступает TF-IDF на текущей разметке
tiny-transformer-classifier	0.488	0.352	ограничен размером и режимом обучения

Из таблицы видно, что TF-IDF + Logistic Regression является наиболее рациональным выбором для текущей версии системы. Она сочетает лучшее качество, простую интерпретацию и достаточную скорость для включения в пользовательский RAG-сценарий.

7. Направления улучшения

Первое направление улучшения связано с балансировкой классов. Если один класс доминирует, модель может склоняться к нему даже при наличии признаков другого влияния. Возможные решения включают взвешивание классов, стратифицированную выборку, oversampling редких классов и более аккуратный подбор порога принятия решения.

Второе направление связано с очисткой и уточнением разметки. Экономические новости часто неоднозначны: одна и та же публикация может быть позитивной для одного сектора и негативной для другого. Если метка задается слишком грубо, модель обучается на шумном сигнале. Улучшение аннотаций и введение правил для спорных случаев может заметно повысить macro F1.

Третье направление состоит в подборе гиперпараметров. Для TF-IDF полезно исследовать диапазон n-грамм, размер словаря, минимальную частоту токенов и регуляризацию логистической регрессии. Для embedding-logreg можно сравнить разные embedding-модели и способы нормализации векторов. Для transformer-классификатора важны learning rate, число эпох, batch size и стратегия early stopping.

Четвертое направление связано с переходом к более сильной transformer-модели. Небольшой классификатор удобен для локального стенда, но ограничен по способности извлекать сложные контекстные зависимости. Более сильная модель, дообученная на

экономических новостях, может лучше распознавать тональность влияния, особенно если в тексте нет явных слов-маркеров.

Пятое направление касается расширения признаков. Помимо текста новости можно использовать дату, источник, тему, макроэкономический показатель, сектор рынка и признаки похожих документов. Комбинация текстовых и структурных признаков может улучшить качество, потому что экономическое влияние часто зависит от контекста события.

Шестое направление относится к тематическому прогнозированию. Текущий прогноз показывает агрегированную картину по корпусу, но его можно развивать через динамику тем во времени, сравнение периодов, оценку устойчивости к шуму и визуализацию трендов. Это сделает систему более полезной для анализа новостного потока, а не только для ответа на отдельный вопрос.

Седьмое направление связано с оценкой retrieval-качества. Для RAG-системы недостаточно иметь хороший классификатор: если поиск возвращает нерелевантные новости, итоговый ответ будет слабым. Поэтому нужно отдельно измерять качество поиска, например через ручную разметку релевантности, precision@k и анализ запросов, на которых источники подбираются хуже всего.

Восьмое направление относится к контролю генерации ответа. Внешний LLM API должен работать в заданных границах: использовать найденный контекст, не добавлять неподтвержденные факты и отделять аналитический вывод от источников. Для этого можно развивать промпт, добавлять автоматические проверки ответа и сохранять трассировку использованных документов.

Девятое направление связано с пользовательской интерпретацией результата. Система может показывать не только итоговый класс влияния, но и распределение вероятностей, наиболее значимые признаки для baseline-модели и объяснение причин выбора источников. Это повысит прозрачность и сделает систему полезнее для учебного и аналитического применения.

Улучшение метрик следует выполнять поэтапно. На первом этапе рационально работать с данными: удалить дубликаты, проверить пустые тексты, нормализовать целевые метки и проанализировать спорные примеры. Если данные содержат шум, усложнение модели может не дать устойчивого прироста качества.

На втором этапе нужно улучшать baseline. Для TF-IDF можно подобрать n-граммы, размер словаря, ``min_df``, ``max_df``, регуляризацию и веса классов. Такой этап

сравнительно дешевый по вычислениям, но часто дает заметный прирост качества именно в текстовых задачах с сильными лексическими признаками.

На третьем этапе можно улучшать embedding-подход. Важно выбрать модель представлений, которая лучше подходит для финансовых и экономических текстов, а также проверить нормализацию эмбедингов. Если embedding лучше отражает смысловую близость новостей, он может усилить не только классификацию, но и retrieval-поиск.

На четвертом этапе имеет смысл переходить к более сильному transformer-классификатору. Для этого нужны веса классов, early stopping, контроль learning rate, достаточное число эпох и сохранение лучшей модели по validation macro F1. Такой подход требует больше ресурсов, но может лучше учитывать контекст слов и сложные формулировки.

На пятом этапе нужно улучшать итоговую систему, а не только отдельную модель. Даже при росте macro F1 важно проверить, стал ли лучше пользовательский ответ: релевантны ли источники, корректно ли формируется прогноз, не теряется ли скорость, понятны ли объяснения. Для диалоговой системы качество модели и качество пользовательского сценария должны оцениваться вместе.

- сбалансировать классы и проверить влияние весов классов на macro F1;
- уточнить правила разметки спорных экономических новостей;
- подобрать гиперпараметры для TF-IDF, embedding и transformer-подходов;
- проверить более сильную transformer-модель на том же test split;
- расширить признаки за счет тем, источников, дат и макроэкономических категорий;
- добавить временную динамику в тематическое прогнозирование.

Заключение

В результате курсовой работы разработана автоматическая диалоговая система для анализа экономических новостей. Система объединяет подготовку данных, классификацию влияния, retrieval-поиск, RAG-ответ, внешний LLM API, тематический прогноз и пользовательский интерфейс. Тем самым проект соответствует заявленной теме и демонстрирует применение машинного обучения в семантическом анализе.

В работе были изучены теоретические основы NLP, классификации текстов, retrieval-augmented generation и использования языковых моделей в аналитических

системах. На основе датасета FNSPID объемом 50 000 новостей сформулирована ML-задача классификации влияния по трем классам: positive, neutral и negative.

Были реализованы и сравнены три модели: TF-IDF + Logistic Regression, embedding-logreg и tiny-transformer-classifier. Лучший результат показала TF-IDF + Logistic Regression, достигнув test accuracy 0.785 и test macro F1 0.717. Интерпретация результатов показала, что классический baseline хорошо отражает доменные лексические признаки текущей разметки.

Архитектура программной системы построена компактно: React UI взаимодействует с API Gateway, а отдельные сервисы отвечают за новости, поиск, анализ и диалог. Qdrant используется для retrieval, Redis для очередей и событий, MLflow для фиксации экспериментов. Backend-часть поддерживает ML-сценарий, но не становится главным предметом записки.

Практическим результатом является система, в которой пользователь задает вопрос, получает ответ по найденным источникам, видит страницы ML-отчета и тематического прогноза. Это отличает проект от простого чат-бота: ответ формируется на основе корпуса новостей и сопровождается проверяемым контекстом.

Поставленная цель достигнута. Основные направления дальнейшего развития включают балансировку классов, уточнение разметки, подбор гиперпараметров, обучение более сильной transformer-модели, расширение признаков и развитие тематического прогнозирования.

Список использованных источников

1. Dong Z. et al. FNSPID: A Comprehensive Financial News Dataset in Time Series [Электронный ресурс]. - URL: <https://arxiv.org/abs/2402.06698> (дата обращения: 28.05.2026). - Текст : электронный.
2. FNSPID: A Comprehensive Financial News Dataset in Time Series : dataset [Электронный ресурс]. - URL: <https://huggingface.co/datasets/beachside1234/FNSPID> (дата обращения: 28.05.2026). - Текст : электронный.
3. Pedregosa F. et al. Scikit-learn: Machine Learning in Python [Электронный ресурс]. - URL: <https://arxiv.org/abs/1201.0490> (дата обращения: 28.05.2026). - Текст : электронный.
4. Scikit-learn documentation [Электронный ресурс]. - URL: <https://scikit-learn.org/stable/> (дата обращения: 28.05.2026). - Текст : электронный.
5. Paszke A. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library [Электронный ресурс]. - URL: <https://arxiv.org/abs/1912.01703> (дата обращения: 28.05.2026). - Текст : электронный.
6. Wolf T. et al. HuggingFace's Transformers: State-of-the-art Natural Language Processing [Электронный ресурс]. - URL: <https://arxiv.org/abs/1910.03771> (дата обращения: 28.05.2026). - Текст : электронный.
7. Lewis P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks [Электронный ресурс]. - URL: <https://arxiv.org/abs/2005.11401> (дата обращения: 28.05.2026). - Текст : электронный.
8. Qdrant documentation [Электронный ресурс]. - URL: <https://qdrant.tech/documentation/> (дата обращения: 28.05.2026). - Текст : электронный.
9. FastAPI documentation [Электронный ресурс]. - URL: <https://fastapi.tiangolo.com/> (дата обращения: 28.05.2026). - Текст : электронный.
10. MLflow documentation [Электронный ресурс]. - URL: <https://mlflow.org/docs/latest/> (дата обращения: 28.05.2026). - Текст : электронный.

Приложения

Приложение А. Ссылка на репозиторий

GitHub-репозиторий проекта: <https://github.com/alexeydev22/news-analysis>

Приложение Б. Сводные факты проекта

Показатель	Значение
Тема	Разработка автоматической диалоговой системы на основе языковой модели для анализа экономических новостей
Датасет	FNSPID
Объем корпуса	50 000 новостей
Классы	negative, neutral, positive
Документы в прогнозе	10 000
Количество тем	2 716
Количество отчетов моделей	3

Приложение В. Роли компонентов ML/RAG-сценария

Компонент	Роль
FNSPID	Корпус экономических новостей для обучения моделей и поиска источников.
TF-IDF + Logistic Regression	Лучший baseline для классификации влияния на текущей разметке.
Qdrant	Векторное хранилище для поиска релевантных новостей по вопросу.
Внешний LLM API	Компонент обобщения найденного контекста в аналитический ответ.
MLflow	Хранение сведений об экспериментах и метриках моделей.